

Deep Learning for Natural Language Processing

Student name: *Ioannis Konstantinou*
sdi: *sdi1700067*

Course: Τεχνητή Νοημοσύνη II (M138, M226, M325)
Semester: Χειμερινό Εξάμηνο 2023

Contents

1	Abstract	2
2	Data Preprocessing and Analysis	2
2.1	Preprocessing	2
2.2	Analysis	2
2.3	Data Split for Training, Testing, and Validation	3
2.4	Vectorization	3
3	Algorithms and Experiments	3
3.1	Initial Baseline Run	3
3.2	Optimization Techniques	4
3.3	Evaluation	4
3.4	Curves	5
4	Results and Analysis of BERT Model	7
4.1	Experiments (BERT)	7
4.2	Hyperparameter Tuning (BERT)	7
4.3	Results from Final Training Run (BERT)	8
4.4	Best Trial (BERT)	9
5	Results and Analysis of DistilBERT Model	9
5.1	Experiments (DistilBERT)	9
5.2	Hyperparameter Tuning (DistilBERT)	9
5.3	Results from Final Training Run (DistilBERT)	10
5.4	Best Trial (DistilBERT)	10
5.5	Hyperparameters	11
6	Overall Analysis and Comparison of BERT and DistilBERT Models	12
6.1	Results Analysis	12
6.2	Comparison between BERT and DistilBERT Models	12
6.3	Further Experiments	13

1. Abstract

Περίληψη Αυτή η εργασία έχει σαν σκοπο το **sentiment analysis** χρησιμοποιώντας μοντέλα βασισμένα σε **Transformers**, συγκεκριμένα τα **BERT** και **DistilBERT**. Η προσέγγιση χρησιμοποιεί ένα προεπαιδευμένο γλωσσικό μοντέλο, ρυθμισμένο σε ένα προσαρμοσμένο σύνολο δεδομένων, με βελτιστοποίηση υπερπαραμέτρων που πραγματοποιείται χρησιμοποιώντας το **Optuna** για τον εντοπισμό της καλύτερης διαμόρφωσης μοντέλου για βελτιωμένες μετρικές απόδοσης όπως το **F1-score** και το **accuracy**. Το τελικό μοντέλο αξιολογείται στο σύνολο δοκιμής και δημιουργούνται προβλέψεις.

2. Data Preprocessing and Analysis

2.1. Preprocessing

Τα βήματα προεπεξεργασίας περιλαμβάνουν κυρίως την ****tokenization**** κατάλληλη για μοντέλα **Transformer**. Αυτό γίνεται από τα **BertTokenizerFast** ή **DistilBertTokenizerFast** της βιβλιοθήκης **transformers**, ανάλογα με το επιλεγμένο μοντέλο. Αυτοί οι **tokenizers** χειρίζονται αυτόματα εργασίες όπως:

- **Tokenization:** Διάσπαση του ακατέργαστου κειμένου σε υπο-λέξεις (**subword units**).
- **Adding special tokens:** Συμπεριλαμβανομένων των **tokens** **[CLS]** και **[SEP]** που απαιτούνται από μοντέλα τύπου **BERT** για εργασίες ταξινόμησης.
- **Padding:** Επέκταση ακολουθιών σε ένα **max_length** με την προσθήκη **tokens** **[PAD]**.
- **Truncation:** Κόψιμο ακολουθιών που είναι μεγαλύτερες από το **max_length**.
- **Creating attention masks:** Δημιουργία **masks** για τη διάκριση μεταξύ πραγματικών **tokens** και **tokens padding**, διασφαλίζοντας ότι το μοντέλο επικεντρώνεται μόνο στα ουσιαστικά μέρη της εισόδου.

Δεν πραγματοποιήθηκε ρητή προσαρμοσμένη καθαρισμός δεδομένων (π.χ., απόρριψη μικρών προτάσεων, αφαίρεση συνδέσμων ή συμβόλων) πέρα από αυτά που χειρίζεται ο **tokenizer**. Σε οποιαδήποτε προσπάθεια για επιπλέον **pre-processing** (προεπεξεργασία) των δεδομένων στα δωσμένα **datasets** ερίχνε ελαφρος τόσο το **f1 score** όσο και το **accuracy**. Για αυτόν τον λόγο δεν χρησιμοποιήθηκε καθόλου **pre-processing** στα πάνω στα υπάρχοντα δεδομένα.

2.2. Analysis

Η αρχική ανάλυση δεδομένων επιβεβαιώνει την επιτυχή φόρτωση των συνόλων δεδομένων και προσδιορίζει τον αριθμό των μοναδικών ετικετών.

- Τα σύνολα δεδομένων φορτώνονται από τα **train_dataset.csv**, **test_dataset.csv**, και **val_dataset.csv**.
- Ο κώδικας βρίσκει και εκτυπώνει τον αριθμό των μοναδικών ετικετών που βρέθηκαν στο σύνολο δεδομένων εκπαίδευσης, κάτι που είναι κρίσιμο για τη διαμόρφωση του επιπέδου εξόδου του μοντέλου ταξινόμησης.

2.3. Data Split for Training, Testing, and Validation

Το σύνολο δεδομένων διαχωρίζεται σε σύνολα εκπαίδευσης, επικύρωσης και δοκιμής όπως παρέχεται από τα αρχεία `train_dataset.csv`, `val_dataset.csv` και `test_dataset.csv`.

- **Training Set (train_df):** Χρησιμοποιείται για την εκπαίδευση του μοντέλου.
- **Validation Set (val_df):** Χρησιμοποιείται κατά τη ρύθμιση υπερπαραμέτρων (από το Optuna) για την αξιολόγηση της απόδοσης του μοντέλου σε δεδομένα που δεν έχουν παρατηρηθεί και για την αποφυγή υπερπροσαρμογής (**overfitting**). Αυτό το σύνολο βοηθά στην επιλογή των καλύτερων υπερπαραμέτρων.
- **Test Set (test_df):** Διατηρείται εντελώς εκτός της διαδικασίας εκπαίδευσης και επικύρωσης. Χρησιμοποιείται μόνο μία φορά στο τέλος για να παρέχει μια αμερόληπτη αξιολόγηση της απόδοσης του τελικού μοντέλου.

2.4. Vectorization

Η τεχνική **vectorization** που χρησιμοποιείται είναι μέσω των **tokenizers** της βιβλιοθήκης **transformers** (`BertTokenizerFast` ή `DistilBertTokenizerFast`). Αυτή η διαδικασία περιλαμβάνει:

- Μετατροπή ακατέργαστου κειμένου σε αριθμητικά `input_ids` (ακέραιες ταυτότητες που αντιστοιχούν σε συγκεκριμένα **tokens**).
- Δημιουργία `attention_mask`, οι οποίοι υποδεικνύουν ποια **tokens** είναι πραγματικό κείμενο (1) και ποια είναι **padding** (0), διασφαλίζοντας ότι το μοντέλο επικεντρώνεται μόνο στα σημαντικά μέρη της εισόδου.
- Για την ταξινόμηση, οι αντίστοιχες `labels` μετατρέπονται σε `torch.long`.

Αυτή η τεχνική είναι σημαντική για την τροφοδοσία δεδομένων κειμένου σε μοντέλα βασισμένα σε **Transformers**.

3. Algorithms and Experiments

3.1. Initial Baseline Run

Η εργασία προσεγγίστηκε αρχικά με μία **baseline** υλοποίηση χρησιμοποιώντας το μοντέλο **DistilBERT** λόγω του ταχύτερου χρόνου εκπαίδευσης σε σύγκριση με το **BERT**. Ο πρωταρχικός στόχος ήταν να παρατηρηθεί η συμπεριφορά και η απόδοση του μοντέλου με ελάχιστες προσαρμογές, και στη συνέχεια να γίνουν επαναληπτικά πειράματα με διαφορετικές τεχνικές για τη βελτίωση των αποτελεσμάτων.

Η **baseline** εκτέλεση περιλάμβανε ένα απλό **fine-tuning** του **DistilBERT** με τις προεπιλεγμένες **hyperparameters**:

- **Model:** `distilbert-base-uncased`
- **Epochs:** 3
- **Batch Size:** 16

- **Learning Rate:** 2e-5
- **Max Token Length:** 128

Αυτή η αρχική εκτέλεση λειτούργησε ως έλεγχος ορθής λειτουργίας και επέτρεψε την παρατήρηση της βασικής δυναμικής εκπαίδευσης για τις μετρικές του μοντέλου όπως για παράδειγμα f1-score, accuracy, precision και recall.

Trial	Model	Epochs	Batch Size	Max Length	Accuracy	F1-Score	Notes
1	DistilBER	3	16	128	0.8463	0.8463	Baseline

Table 1: Αποτελέσματα Αρχικής Εκτέλεσης (Baseline)

3.2. Optimization Techniques

Η κύρια τεχνική βελτιστοποίησης που χρησιμοποιείται είναι το **Optuna**.

- **Optuna Study:** Μία `optuna.create_study` αρχικοποιήθηκε με `direction="maximize"` για το F1-score επικύρωσης και έναν `MedianPruner` για την αποτελεσματική τερματισμό των δοκιμών με χαμηλή απόδοση.
- **AdamW Optimizer:** Ο βελτιστοποιητής AdamW από το PyTorch χρησιμοποιήθηκε για την εκπαίδευση του μοντέλου. Αυτός ο βελτιστοποιητής είναι μια παραλλαγή του Adam που περιλαμβάνει τακτοποίηση αποσύνθεσης βάρους, η οποία είναι κρίσιμη για την εκπαίδευση μεγάλων μοντέλων όπως τα Transformers. Οι υπερπαραμέτροι για τον AdamW όπως ο `learning_rate`, το `eps`, και το `weight_decay` ρυθμίστηκαν από το Optuna.
- **Linear Scheduler with Warmup:** Χρησιμοποιήθηκε το `get_linear_schedule_with_warmup` για τη ρύθμιση του ρυθμού εκμάθησης κατά την εκπαίδευση. Αυτός ο scheduler αυξάνει γραμμικά τον ρυθμό εκμάθησης κατά τη φάση **warmup** και στη συνέχεια τον μειώνει γραμμικά. Ο `warmup_ratio` ήταν επίσης μια υπερπαραμέτρος που ρυθμίστηκε από το Optuna.
- **Gradient Clipping:** Η `torch.nn.utils.clip_grad_norm_` εφαρμόστηκε κατά την εκπαίδευση με μια τιμή `grad_clip_norm`. Αυτή η τεχνική βοηθά στην πρόληψη των εκρηκτικών κλίσεων (**exploding gradients**), ένα κοινό πρόβλημα στα βαθιά νευρωνικά δίκτυα, με τη κλιμάκωση των κλίσεων όταν ο κανόνας L2 τους υπερβαίνει ένα όριο.

3.3. Evaluation

Η αξιολόγηση πραγματοποιείται στο **validation dataset** κατά τη ρύθμιση των υπερπαραμέτρων και στο **validation dataset** κατά την τελική φάση εκπαίδευσης για την παρακολούθηση της προόδου.


Οι χρησιμοποιούμενες μετρικές είναι:


- **Accuracy (accuracy_score):** Το ποσοστό των σωστά ταξινομημένων περιπτώσεων επί του συνόλου των περιπτώσεων.

- **Precision, Recall, F1-Score (precision_recall_fscore_support):** Αυτές οι μετρικές υπολογίζονται με `average='weighted'` για να ληφθεί υπόψη η ανισορροπία των ετικετών (εάν υπάρχει).
 - **Precision:** Ο λόγος των αληθών θετικών προβλέψεων προς το σύνολο των θετικών προβλέψεων (αληθή θετικά + ψευδή θετικά).
 - **Recall:** Ο λόγος των αληθών θετικών προβλέψεων προς το σύνολο των πραγματικά θετικών περιπτώσεων (αληθή θετικά + ψευδή αρνητικά).
 - **F1-Score:** Ο αρμονικός μέσος όρος του **recall** και του **accuracy**. Είναι ιδιαίτερα χρήσιμο όταν αντιμετωπίζονται μη ισορροπημένα σύνολα δεδομένων, καθώς εξισορροπεί τόσο το **accuracy** όσο και το **recall**.


3.4. Curves

Οι καμπύλες απο το **baseline model**






Οι καμπύλες απο το **best DistilBERT model**



Οι καμπύλες απο το **best BERT model**



4. Results and Analysis of BERT Model

4.1. Experiments (BERT)

Οι δοκιμές Optuna για το μοντέλο BERT επικεντρώθηκαν στην εύρεση των καλύτερων υπερπαραμέτρων για το BERT μοντέλο (bert-base-uncased).

- **Hyperparameter Variation:** Για κάθε δοκιμή, το Optuna πρότεινε τιμές για:
 - Ρυθμός Εκμάθησης (learning_rate): Εύρος log-uniform από 1×10^{-6} έως 5×10^{-5} .
 - Μέγεθος Batch (batch_size): Κατηγορικές επιλογές 4, 8, 16, 32.
 - Εποχές (epochs): Ακέραιο εύρος από 2 έως 4.
 - Μέγιστο Μήκος Ακολουθίας (max_length): Κατηγορικές επιλογές 32, 64.
 - Epsilon Βελτιστοποιητή (optimizer_eps): Εύρος log-uniform από 1×10^{-9} έως 1×10^{-7} .
 - Λόγος Warmup (warmup_ratio): Εύρος float από 0.0 έως 0.1.
 - Όριο αποκοπής κλίσης (grad_clip_norm): Εύρος float από 0.5 έως 1.5.
 - Βάρος αποσύνθεσης (weight_decay): Εύρος float από 0.0 έως 0.05.
 - Ποσοστά Dropout (attention_dropout, hidden_dropout): Εύρος float από 0.1 έως 0.2.

4.2. Hyperparameter Tuning (BERT)

Η ρύθμιση υπερπαραμέτρων πραγματοποιήθηκε χρησιμοποιώντας το Optuna. Η μελέτη διήρκεσε για 25 δοκιμές. Οι καλύτερες υπερπαραμέτροι που βρέθηκαν από το Optuna για το BERT ήταν:

- model_type: bert (συγκεκριμένα bert-base-uncased)

- learning_rate: 1.739×10^{-5}
- batch_size: 16
- epochs: 2
- max_length: 64
- optimizer_eps: 1.674×10^{-9}
- warmup_ratio: 0.017
- grad_clip_norm: 1.266
- weight_decay: 0.0071
- attention_dropout: 0.193 hidden_dropout: 0.189

4.3. Results from Final Training Run (BERT)

Αποτελέσματα από την τελική εκτέλεση εκπαίδευσης (στο Σύνολο Επικύρωσης - BERT):

- **Epoch 1:**
 - Training Loss: 0.3946
 - Validation Loss: 0.3519
 - Validation Accuracy: 0.8505
 - Validation Precision: 0.8510
 - Validation Recall: 0.8505
 - Validation F1-Score: 0.8505
- **Epoch 2:**
 - Training Loss: 0.3094
 - Validation Loss: 0.3570
 - Validation Accuracy: 0.8564
 - Validation Precision: 0.8565
 - Validation Recall: 0.8564
 - Validation F1-Score: 0.8564
- Η **Validation Accuracy** και το **Validation F1-score** δείχνουν αυξητική τάση από την Εποχή 1 στην Εποχή 2, υποδεικνύοντας ότι το μοντέλο συνέχισε να μαθαίνει και να βελτιώνει την απόδοση στο σύνολο επικύρωσης.
- Η **Training Loss** μειώθηκε σταθερά στις εποχές, κάτι που είναι αναμενόμενο καθώς το μοντέλο μαθαίνει να προσαρμόζεται στα δεδομένα εκπαίδευσης.
- Η **Validation Loss** αυξήθηκε ελαφρώς στη δεύτερη εποχή (από 0.3519 σε 0.3570). Αυτή η μικρή αύξηση, ενώ η απώλεια εκπαίδευσης συνεχίζει να μειώνεται, μπορεί να υποδηλώνει την αρχή του **overfitting** ή απλώς ένα πλατό. Δεδομένου ότι το **F1-score** και η ακρίβεια συνέχισαν να βελτιώνονται, το μοντέλο φαίνεται να γενικεύει καλά για 2 εποχές με τις επιλεγμένες υπερπαραμέτρους.

4.4. Best Trial (BERT)

Η καλύτερη δοκιμή που εντοπίστηκε από το Optuna απέδωσε μέγιστο F1-score επικύρωσης **0.8564**.

- **Model Type:** bert
- **Key Hyperparameters:** Ρυθμός Εκμάθησης: 1.739×10^{-5} , Μέγεθος Batch: 16, Μέγιστο Μήκος: 64.

5. Results and Analysis of DistilBERT Model

5.1. Experiments (DistilBERT)

Οι δοκιμές Optuna για το μοντέλο DistilBERT επικεντρώθηκαν στην εύρεση των καλύτερων υπερπαραμέτρων για το DistilBERT model (distilbert-base-uncased).

- **Hyperparameter Variation:** Τα εύρη των υπερπαραμέτρων ήταν τα ίδια με αυτά που αναφέρθηκαν προηγουμένως, αλλά οι βέλτιστες τιμές διαφέρουν για το DistilBERT.

5.2. Hyperparameter Tuning (DistilBERT)

Η ρύθμιση υπερπαραμέτρων πραγματοποιήθηκε χρησιμοποιώντας το Optuna. Η μελέτη διήρκεσε για 25 δοκιμές. Οι καλύτερες υπερπαραμέτροι που βρέθηκαν από το Optuna για το DistilBERT ήταν:

- model_type: distilbert (συγκεκριμένα distilbert-base-uncased)
- learning_rate: 1.786×10^{-5}
- batch_size: 8
- epochs: 2
- max_length: 64
- optimizer_eps: 2.596×10^{-8}
- warmup_ratio: 0.057
- grad_clip_norm: 1.302
- weight_decay: 0.0083
- attention_dropout: 0.113 hidden_dropout: 0.184

5.3. Results from Final Training Run (DistilBERT)

Αποτελέσματα από την τελική εκτέλεση εκπαίδευσης (στο Σύνολο Επιχώρωσης - DistilBERT):

- **Epoch 1:**
 - Training Loss: 0.4154
 - Validation Loss: 0.3760
 - Validation Accuracy: 0.8415
 - Validation Precision: 0.8417
 - Validation Recall: 0.8415
 - Validation F1-Score: 0.8415
- **Epoch 2:**
 - Training Loss: 0.3197
 - Validation Loss: 0.4155
 - Validation Accuracy: 0.8491
 - Validation Precision: 0.8491
 - Validation Recall: 0.8491
 - Validation F1-Score: 0.8491

Comments on Learning Curves (for DistilBERT): Οι καμπύλες μάθησης για το DistilBERT δείχνουν την εξέλιξη των μετρικών ανά εποχή.

- Η **Validation Accuracy** και το **Validation F1-score** δείχνουν μια αυξητική τάση από την Εποχή 1 στην Εποχή 2.
- Η **Training Loss** μειώθηκε σταθερά στις εποχές.
- Η **Validation Loss** αυξήθηκε από 0.3760 σε 0.4155 στην Εποχή 2. Αυτή η αύξηση, σε συνδυασμό με τη συνεχιζόμενη μείωση της απώλειας εκπαίδευσης, υποδηλώνει την έναρξη του **overfitting**.

5.4. Best Trial (DistilBERT)

Η καλύτερη δοκιμή που εντοπίστηκε από το Optuna απέδωσε μέγιστο F1-score επιχώρωσης **0.8491**.

- **Model Type:** distilbert
- **Key Hyperparameters:** Ρυθμός Εκμάθησης: 1.786×10^{-5} , Μέγεθος Batch: 8, Μέγιστο Μήκος: 64.

Αυτή η δοκιμή επιβεβαιώνει μια διαμόρφωση που οδήγησε σε υψηλή απόδοση γενίκευσης στο σύνολο δεδομένων επιχώρωσης για το DistilBERT.

5.5. Hyperparameters

Οι παρακάτω παράμετροι χρησιμοποιήθηκαν για τη βελτιστοποίηση και σταθεροποίηση της εκπαίδευσης των μοντέλων **Transformer** (**BERT** και **DistilBERT**) και ρυθμίστηκαν συστηματικά μέσω του **Optuna** για την επίτευξη της καλύτερης απόδοσης:

- **optimizer eps**: Αυτή η μικρή τιμή προστίθεται στον παρονομαστή κατά τον υπολογισμό των ενημερώσεων των βαρών στον βελτιστοποιητή **AdamW**. Ο κύριος σκοπός της είναι να αποτρέψει τη διαίρεση με το μηδέν όταν ο παρονομαστής είναι πολύ μικρός, διασφαλίζοντας την αριθμητική σταθερότητα του αλγορίθμου. Βοηθά επίσης στην αποφυγή ακραίων τιμών στις ενημερώσεις των βαρών, ιδιαίτερα σε περιπτώσεις όπου οι κλίσεις είναι πολύ μικρές.
- **warmup_ratio**: Καθορίζει το ποσοστό των συνολικών βημάτων εκπαίδευσης κατά το οποίο ο ρυθμός μάθησης (**learning rate**) αυξάνεται γραμμικά από το 0 στην αρχική του τιμή. Μετά την περίοδο "θέρμανσης" (**warmup**), ο ρυθμός μάθησης μειώνεται σταδιακά. Αυτή η τεχνική είναι ζωτικής σημασίας για την εκπαίδευση μοντέλων **Transformer**:
 - Βοηθά στην αρχική σταθεροποίηση: Η αργή έναρξη της μάθησης επιτρέπει στο μοντέλο να βρει μια πιο σταθερή αρχική κατάσταση, αποφεύγοντας μεγάλες ενημερώσεις βαρών που θα μπορούσαν να οδηγήσουν σε ασταθή σύγκλιση ή απόκλιση στην αρχή της εκπαίδευσης.
 - Βελτιώνει τη γενίκευση: Συμβάλλει στο να βρει το μοντέλο ένα καλύτερο ελάχιστο στην συνάρτηση απώλειας.
- **grad_clip_norm**: Αυτή η παράμετρος ορίζει ένα μέγιστο όριο για τον κανόνα (**norm**) των κλίσεων. Εάν ο κανόνας των κλίσεων υπερβεί αυτή την τιμή, οι κλίσεις κλιμακώνονται προς τα κάτω (**clipping**) ώστε να μην την υπερβούν. Ο σκοπός της είναι να αποτρέψει το φαινόμενο των "εκρηκτικών κλίσεων" (**exploding gradients**), όπου οι κλίσεις γίνονται πολύ μεγάλες, οδηγώντας σε ασταθή ενημέρωση των βαρών και ενδεχομένως σε απόκλιση του μοντέλου. Είναι ιδιαίτερα χρήσιμη σε βαθιά νευρωνικά δίκτυα όπως οι **Transformers**.
- **weight_decay**: Πρόκειται για μια τεχνική τακτοποίησης (**regularization**) που προσθέτει έναν όρο στην συνάρτηση απώλειας, ανάλογο του τετραγώνου των βαρών του μοντέλου (**L2 regularization**). Αυτός ο όρος τιμωρεί τα μεγάλα βάρη, ενθαρρύνοντας το μοντέλο να χρησιμοποιεί μικρότερα βάρη. Ο κύριος στόχος του είναι να μειώσει την υπερπροσαρμογή (**overfitting**), βελτιώνοντας τη γενίκευση του μοντέλου σε μη ορατά δεδομένα, καθώς περιορίζει την πολυπλοκότητα του μοντέλου.
- **attention_dropout**: Αυτή η παράμετρος καθορίζει το ποσοστό των συνδέσεων στα επίπεδα προσοχής (**attention layers**) του **Transformer** που απενεργοποιούνται τυχαία κατά την εκπαίδευση.
 - Μείωση υπερπροσαρμογής: Εμποδίζει τις συν-εξαρτήσεις μεταξύ των νευρώνων, αναγκάζοντας το μοντέλο να μάθει πιο ισχυρές και ανεξάρτητες αναπαραστάσεις.
 - Βελτίωση γενίκευσης: Κάνει το μοντέλο λιγότερο ευαίσθητο σε συγκεκριμένες εισόδους ή διαδρομές στον πίνακα προσοχής, οδηγώντας σε καλύτερη απόδοση σε νέα δεδομένα.

- **hidden_dropout (Dropout στα κρυφά επίπεδα):** Αυτή η παράμετρος καθορίζει το ποσοστό των νευρώνων στα κρυφά (**feed-forward**) επίπεδα κάθε μπλοκ Transformer που απενεργοποιούνται τυχαία κατά την εκπαίδευση.
 - Μείωση υπερπροσαρμογής: Λειτουργεί παρόμοια με το **attention_dropout**, αποτρέποντας την υπερβολική εξάρτηση από συγκεκριμένους νευρώνους και ενθαρρύνοντας την ανάπτυξη πιο διασκορπισμένων και ανθεκτικών αναπαραστάσεων.
 - Βελτίωση γενίκευσης: Συμβάλλει στην ικανότητα του μοντέλου να αποδίδει καλά σε δεδομένα που δεν έχει δει.

6. Overall Analysis and Comparison of BERT and DistilBERT Models

6.1. Results Analysis

Τα αποτελέσματα καταδεικνύουν μια καλή απόδοση, με τα δύο μοντέλα Transformer, BERT και DistilBERT, μετά τη ρύθμιση υπερπαραμέτρων μέσω του Optuna.

Feature / Metric	BERT (bert-base-uncased)	DistilBERT (distilbert-base-uncased)
Best Validation F1-Score	0.8564	0.8491
Best Validation Accuracy	0.8564	0.8491
Validation Loss (Final Epoch)	0.3570	0.4155
Batch Size (Optimal)	16	8
Epochs (Optimal)	2	2
Max Sequence Length (Optimal)	64	64

6.2. Comparison between BERT and DistilBERT Models

- **Performance:** Το μοντέλο BERT παρουσίασε ελαφρώς καλύτερη απόδοση, επιτυγχάνοντας μέγιστο F1-score και accuracy 0.8564 έναντι 0.8491 του DistilBERT. Αυτή η διαφορά, αν και μικρή, υποδηλώνει ότι το BERT, όντας ένα μεγαλύτερο μοντέλο, πιθανώς καταφέρνει να συλλάβει πιο σύνθετα πρότυπα στα δεδομένα για αυτήν την εργασία.
- **Overfitting:** Παρατηρήσαμε ότι το validation loss του DistilBERT αυξήθηκε στην δεύτερη εποχή, κάτι που υποδηλώνει την έναρξη της υπερπροσαρμογής. Αντίθετα, το BERT διατήρησε μια πιο σταθερή validation loss, υποδεικνύοντας καλύτερη γενίκευση με τις επιλεγμένες υπερπαραμέτρους. Αυτό οφείλεται στην εγγενή πολυπλοκότητα του BERT που του επιτρέπει να μαθαίνει πιο ισχυρές αναπαραστάσεις.
- **Batch Size:** Το Optuna πρότεινε ένα μεγαλύτερο batch size (16) για το BERT σε σύγκριση με το DistilBERT (8). Αυτό μπορεί να επηρεάζει την σταθερότητα της εκπαίδευσης και την γενίκευση.

Comparison Conclusion: Για την συγκεκριμένη εργασία και το συγκεκριμένο σύνολο δεδομένων, το BERT προσφέρει μια ελαφρώς ανώτερη απόδοση όσον αφορά το F1-score αλλά και accuracy και φάνηκε να υπερπροσαρμόζεται λιγότερο εντός των 2 εποχών.

6.3. Further Experiments

- **More Epochs:** Για το BERT, ίσως άξιζε να δοκιμάσω μερικές ακόμη εποχές (π.χ., 5-10) για να δώ αν η απόδοση θα μπορούσε να σταθεροποιηθεί περαιτέρω ή να βελτιωθεί πριν ξεκινήσει η σαφής υπερπροσαρμογή (αν και το `optuna` σχεδόν ποτέ δεν επέλεγε το παραπάνω από 2 epochs ως τα βέλτιστα). Για το DistilBERT, η αύξηση της απώλειας επικύρωσης υποδηλώνει ότι η αύξηση των εποχών μπορεί να οδηγήσει σε περαιτέρω υπερπροσαρμογή.
- **Cross-validation:** Αντί για ένα σταθερό διαχωρισμό εκπαίδευσης/επικύρωσης, η χρήση **k-fold cross-validation** κατά την τελική φάση εκπαίδευσης (μετά τη ρύθμιση υπερ-παραμέτρων) μπορεί να παρέχει μια πιο ισχυρή εκτίμηση της απόδοσης του μοντέλου και να βοηθήσει στην ανίχνευση αστάθειας.